

```

1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5 import torch
6 import glob
7 import os
8
9 from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score, accuracy_score, confusion_matrix, ConfusionMatrixDisplay

```

```

1 from google.colab import drive
2 drive.mount('/content/drive')

```

Mounted at /content/drive

```

1 files_joined = os.path.join('/content/drive/MyDrive/Inteligencia Artificial/Segundo Parcial/Proyecto', "Indicadores*csv")
2 list_files = glob.glob(files_joined)
3 df = pd.concat(map(pd.read_csv, list_files), ignore_index=True)
4 df.sample(n=5)

```

	AÑO	EXPEDIENTE	NOMBRE	RAMA	DESCRIPCION
54388	2018	60169	AVICOLA Y COMERCIALIZADORA ZARACAY AVI & COMZA...	A	AGRICULTURA GANADERA SILVICULTURA PESQUERÍA
161002	2020	138119	EXPORTAJAIME S.A.	G	COMERCIO POR MAYOR POR MENOR REPARACION
5974	2017	42464	INMOBILIARIAAMUS SA	L	ACTIVIDADES INMOBILIARIAS
30056	2017	163026	ESTUDIO SPINGARN & MARKS S.A.	M	ACTIVIDADES PROFESIONALES CIENTÍFICAS TÁCTICAS

```

1 df = df[(df['ROE']>-1) & (df['ROE']<1) & (df['ROA']>-1) & (df['ROA']<1) & (df['ENDEUDAMIENTO DEL ACTIVO']<6) & (df['RENTABILIDAD NETA DE VENTAS']>-50) &
2 (df['UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ']>-5) & (df['UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ']<5) & (df['RENTABILIDAD FINANCIERA']<500)]
3 df['ROA_DIS'] = pd.qcut(df['ROA'], 3, labels=False)

```

```

1 # Crear los arreglos con los inputs escogidos y el target del ROA
2 inputs_rlg = df[['RENTABILIDAD NETA DEL ACTIVO', 'UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ', 'RENTABILIDAD FINANCIERA', 'RENTABILIDAD NETA DE VENTAS']].values
3 targets_rlg = df['ROA_DIS'].values
4 print('Input #1: ', inputs_rlg[1], ' - Tamaño: ', inputs_rlg.shape,
5       '\nTarget #1: ', targets_rlg[1], ' - Tamaño: ', targets_rlg.shape)

```

```

Input #1:  [0.02223394 0.21433391 0.05166009 0.03359371] - Tamaño:  (188887, 4)
Target #1:  1 - Tamaño:  (188887,)

```

```

1 # Normalizar los inputs
2 bs=32
3 from sklearn.preprocessing import StandardScaler
4 from torch.utils.data import TensorDataset, DataLoader
5 scaler = StandardScaler()
6 x_train = scaler.fit_transform(inputs_rlg)

```

```

1 x_train = torch.from_numpy(x_train.astype(np.float32))
2 y_train = torch.from_numpy(targets_rlg.astype(np.int64))

```

```

1 class MultilayerPerceptron(torch.nn.Module):
2     def __init__(self, n_features, n_classes):
3         super(MultilayerPerceptron, self).__init__()
4         self.hidden_layer_1 = torch.nn.Linear(n_features, 64) # Primera capa oculta con 32 neuronas
5         self.hidden_layer_2 = torch.nn.Linear(64, 32) # Segunda capa oculta con 16 neuronas
6         self.hidden_layer_3 = torch.nn.Linear(32, 16) # Segunda capa oculta con 16 neuronas
7         self.output_layer = torch.nn.Linear(16, n_classes) # Capa de salida con 3 neuronas
8         self.relu = torch.nn.ReLU()
9         self.softmax = torch.nn.Softmax(dim=1)
10
11     def forward(self, x):
12         hidden_1 = self.relu(self.hidden_layer_1(x))
13         hidden_2 = self.relu(self.hidden_layer_2(hidden_1))
14         hidden_3 = self.relu(self.hidden_layer_3(hidden_2))
15         y_hat = self.softmax(self.output_layer(hidden_3))
16         return y_hat
17
18 """class MultilayerPerceptron(torch.nn.Module):
19     def __init__(self, n_features, n_classes):
20         super(MultilayerPerceptron, self).__init__()
21         self.hidden_layer = torch.nn.Linear(n_features, 10) # Capa oculta con 10 neuronas
22         self.output_layer = torch.nn.Linear(10, n_classes) # Capa de salida con 3 neuronas

```

```

23     self.relu = torch.nn.ReLU()
24     self.softmax = torch.nn.Softmax(dim=1)
25
26 def forward(self, x):
27     hidden = self.relu(self.hidden_layer(x))
28     y_hat = self.softmax(self.output_layer(hidden))
29     return y_hat"""
30
31 #función que visualiza la evolución de la pérdida y la precisión en cada epoch
32 def plot_loss(epochs, loss, acc):
33     plt.figure(figsize=(10, 5))
34     xlim = len(loss)
35     plt.plot(epochs,loss)
36     plt.plot(epochs,acc)
37     plt.xlabel('Epochs')
38     plt.ylabel('Value')
39     plt.legend(('Train loss','Accuracy'),loc='upper right',shadow=True)
40     plt.title('Train Loss vs Accuracy')
41
42 #función que realiza el entrenamiento
43 def train(num_epochs, optimizer, cost, model):
44     #listas usadas para guardar los valores de pérdida, precisión, para cada epoch
45     #esta información sirve para graficar el proceso de entrenamiento
46     loss_vals = []
47     acc_vals = []
48     epoch_vals = []
49
50     #entrenamiento
51     for epoch in range(num_epochs):
52         y_hat = model(x_train)
53         loss = cost(y_hat,y_train)
54         loss.backward()
55         optimizer.step()
56         optimizer.zero_grad()
57
58         #se evalua cada 5 epochs
59         if (epoch+1)%999 == 0:
60             with torch.no_grad():
61                 loss_vals.append(loss.item())
62                 y_hat_class = y_hat.argmax(dim=1)
63                 accuracy = (y_hat_class.eq(y_train).sum())/float(y_hat.shape[0])
64                 acc_vals.append(accuracy.item())
65                 epoch_vals.append(epoch+1)
66                 print(f'epoch:{epoch+1} loss={loss.item()} accuracy={accuracy.item()}')
67
68     #se grafica el proceso de entrenamiento
69     plot_loss(epoch_vals, loss_vals, acc_vals)

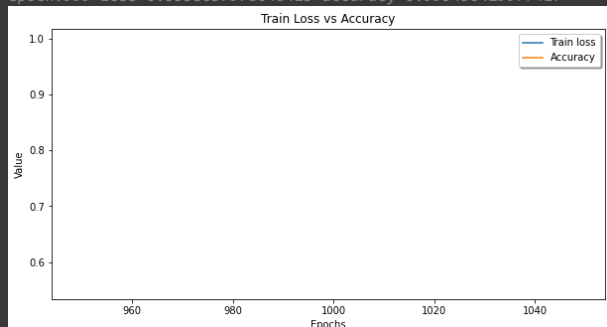
```

```

1 model_rlg = MultilayerPerceptron(inputs_rlg.shape[1], len(np.unique(targets_rlg)))
2 optimizer = torch.optim.Adam(model_rlg.parameters(), lr=0.09)
3 cost = torch.nn.CrossEntropyLoss()
4 # se entrena el modelo
5 train(num_epochs=1000, optimizer=optimizer, cost=cost, model=model_rlg)

```

epoch:999 loss=0.5558637976646423 accuracy=0.995436429977417



```

1 desc = ['COMERCIO AL POR MAYOR Y AL POR MENOR REPARACIÓ“N DE VEHÍCULOS AUTOMOTORES Y MOTOCICLETAS.', 'INDUSTRIAS MANUFACTURERAS.', 'AGRICULTURA, GANADERÍA, SILVICULTURA Y F
2     'ACTIVIDADES PROFESIONALES, CIENTÍFICAS Y TÉCNICAS.', 'ACTIVIDADES DE ALOJAMIENTO Y DE SERVICIO DE COMIDAS.', 'INFORMACIÓ“N Y COMUNICACIÓ“N.', 'ACTIVIDADES DE SERVICIOS
3     'ACTIVIDADES DE ATENCIÓ“N DE LA SALUD HUMANA Y DE ASISTENCIA SOCIAL.', 'TRANSPORTE Y ALMACENAMIENTO.', 'ACTIVIDADES INMOBILIARIAS.', 'EXPLOTACIÓ“N DE MINAS Y CANTERAS.',
4     'DISTRIBUCIÓ“N DE AGUA ALCANTARILLADO, GESTIÓ“N DE DESECHOS Y ACTIVIDADES DE SANEAMIENTO.', 'SUMINISTRO DE ELECTRICIDAD, GAS, VAPOR Y AIRE ACONDICIONADO.',
5     'ARTES, ENTRETENIMIENTO Y RECREACIÓ“N.', 'ENSEÑANZA.', 'ACTIVIDADES FINANCIERAS Y DE SEGUROS.', 'ACTIVIDADES DE ORGANIZACIONES Y ÓRGANOS EXTRATERRITORIALES.']

```

```

1 desc_good = ["COMERCIO AL POR MAYOR Y AL POR MENOR REPARACIÓN DE VEHÍCULOS AUTOMOTORES Y MOTOCICLETAS.", "INDUSTRIAS MANUFACTURERAS.", "AGRICULTURA, GANADERÍA, SILVICULTURA Y F
2     "ACTIVIDADES PROFESIONALES, CIENTÍFICAS Y TÉCNICAS.", "ACTIVIDADES DE ALOJAMIENTO Y DE SERVICIO DE COMIDAS.", "INFORMACIÓN Y COMUNICACIÓN.", "ACTIVIDADES DE SERVICIOS ADMINIST
3     "ACTIVIDADES DE ATENCIÓN DE LA SALUD HUMANA Y DE ASISTENCIA SOCIAL.", "TRANSPORTE Y ALMACENAMIENTO.", "ACTIVIDADES INMOBILIARIAS.", "EXPLOTACIÓN DE MINAS Y CANTERAS.",
4     "OTRAS ACTIVIDADES DE SERVICIOS.", "DISTRIBUCIÓN DE AGUA ALCANTARILLADO, GESTIÓN DE DESECHOS Y ACTIVIDADES DE SANEAMIENTO.", "SUMINISTRO DE ELECTRICIDAD, GAS, VAPOR Y AIRE ACON
5     "ARTES, ENTRETENIMIENTO Y RECREACIÓN.", "ENSEÑANZA.", "ACTIVIDADES FINANCIERAS Y DE SEGUROS.", "ACTIVIDADES DE ORGANIZACIONES Y ÓRGANOS EXTRATERRITORIALES."]

```

```

1 print(model_rlg)

```

```

MultilayerPerceptron(
  (hidden_layer_1): Linear(in_features=4, out_features=64, bias=True)
  (hidden_layer_2): Linear(in_features=64, out_features=32, bias=True)
  (hidden_layer_3): Linear(in_features=32, out_features=16, bias=True)
  (output_layer): Linear(in_features=16, out_features=3, bias=True)
  (relu): ReLU()
  (softmax): Softmax(dim=1)
)

```

```

1 def categoria_rlg():
2     # Remover Outliers
3     dfp = df[(df['ROE']>-1) & (df['ROE']<1) & (df['ROA']>-1) & (df['ROA']<1) & (df['ENDEUDAMIENTO DEL ACTIVO']<6) & (df['RENTABILIDAD NETA DE VENTAS']>-50) &
4         (df['UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ']>-5) & (df['UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ']<5) & (df['RENTABILIDAD FINANCIERA']<500)]
5
6     dfp['ROA_DIS'] = pd.qcut(dfp['ROA'], 3, labels=False)
7     #dfp["DESCRIPCIÓN RAMA"] = dfp[["DESCRIPCIÓN RAMA"]].values
8     metrics = {"Categoria": [], "MAE": [], "MSE": [], "RMSE": [], "ACC": []}
9     dfp['DESCRIPCIÓN RAMA'].replace(desc, desc_good, inplace=True)
10    grouped = dfp.groupby("DESCRIPCIÓN RAMA")
11    for name, group in grouped:
12        inputs_rlg = group[['RENTABILIDAD NETA DEL ACTIVO', 'UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ', 'RENTABILIDAD FINANCIERA', 'RENTABILIDAD NETA DE VENTAS']].values
13        targets_rlg = group[['ROA_DIS']].values
14        # Escalando los datos
15        scaler = StandardScaler()
16        inputs = scaler.fit_transform(inputs_rlg)
17        # Transformando los datos a tensores
18        inputs_rlg = torch.from_numpy(inputs.astype(np.float32))
19        targets_rlg = torch.from_numpy(targets_rlg.astype(np.int64))
20        # Creando el conjunto de datos de test
21        dataset_test = TensorDataset(inputs_rlg, targets_rlg)
22        test_loader = DataLoader(dataset_test, batch_size=bs, shuffle=True)
23        # Evaluando el modelo
24        y_pred = []
25        y_true = []
26        model_rlg.train(False)
27        for inputs, targets in test_loader:
28            y_hat_test = model_rlg(inputs).data.numpy()
29            y_hat_class = np.argmax(y_hat_test, axis=1)
30            y_pred.extend(y_hat_class)
31            y_true.extend(targets.numpy())
32        # Calculando métricas
33        mae = mean_absolute_error(y_true=y_true, y_pred=y_pred)
34        mse = mean_squared_error(y_true=y_true, y_pred=y_pred, squared=True)
35        rmse = mean_squared_error(y_true=y_true, y_pred=y_pred, squared=False)
36        acc = accuracy_score(y_true, y_pred)
37        # Imprimiendo los resultados
38        metrics["Categoria"].append(name)
39        metrics["MAE"].append(mae)
40        metrics["MSE"].append(mse)
41        metrics["RMSE"].append(rmse)
42        metrics["ACC"].append(acc)
43
44    metrics_df_ = pd.DataFrame(metrics)
45    return metrics_df_

```

```
1 metrics_rlg = categoria_rlg()
```

```
1 metrics_rlg.sort_values("ACC", ascending=False)
```

	Categoria	MAE	MSE	RMSE	ACC
16	OTRAS ACTIVIDADES DE SERVICIOS.	0.072267	0.072267	0.268826	0.927733
12	ENSEÑANZA.	0.103690	0.104428	0.323153	0.896679
10	CONSTRUCCIÓN.	0.125271	0.125271	0.353937	0.874729
15	INFORMACIÓN Y COMUNICACIÓN.	0.142343	0.144329	0.379906	0.858650
7	AGRICULTURA, GANADERÍA, SILVICULTURA Y PESCA.	0.145672	0.146477	0.382723	0.854730
11	DISTRIBUCIÓN DE AGUA ALCANTARILLADO, GESTIÓN D...	0.161883	0.168772	0.410818	0.841561
9	COMERCIO AL POR MAYOR Y AL POR MENOR REPARACIÓ...	0.158655	0.158784	0.398477	0.841409
1	ACTIVIDADES DE ATENCIÓN DE LA SALUD HUMANA Y D...	0.161006	0.164528	0.405621	0.840755
18	TRANSPORTE Y ALMACENAMIENTO.	0.193956	0.194190	0.440670	0.806161

```

1 def procesar_rlg(año):
2     # Remover Outliers
3     dfl = df[(df['ROE'] > -1) & (df['ROE'] < 1) & (df['ROA'] > -1) & (df['ROA'] < 1) & (df['ENDEUDAMIENTO DEL ACTIVO'] < 6) & (df['RENTABILIDAD NETA DE VENTAS'] > -50) &
4         (df['UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ' > -5) & (df['UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ' < 5) & (df['RENTABILIDAD FINANCIERA'] < 500)]
5     dfl['ROA_DIS'] = pd.qcut(dfl['ROA'], 3, labels=False)
6     dfl = dfl[dfl['AÑO'] == año]
7     # Input y Targets
8     inputs_rlg = dfl[['RENTABILIDAD NETA DEL ACTIVO', 'UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ', 'RENTABILIDAD FINANCIERA', 'RENTABILIDAD NETA DE VENTAS']].values
9     targets_rlg = dfl[['ROA_DIS']].values
10    # Escalando los datos
11    scaler = StandardScaler()

```

```

12 inputs = scaler.fit_transform(inputs_rlg)
13 # Transformando los datos a tensores
14 inputs_rlg = torch.from_numpy(inputs.astype(np.float32))
15 targets_rlg = torch.from_numpy(targets_rlg.astype(np.int64))
16 # Creando el conjunto de datos de test
17 dataset_test = TensorDataset(inputs_rlg, targets_rlg)
18 test_loader = DataLoader(dataset_test, batch_size=bs, shuffle=True)
19 # Evaluando el modelo
20 y_pred = []
21 y_true = []
22 model_rlg.train(False)
23 for inputs, targets in test_loader:
24     y_hat_test = model_rlg(inputs).data.numpy()
25     y_hat_class = np.argmax(y_hat_test, axis=1)
26     y_pred.extend(y_hat_class)
27     y_true.extend(targets.numpy())
28 # Calculando métricas
29 mae = mean_absolute_error(y_true=y_true, y_pred=y_pred)
30 mse = mean_squared_error(y_true=y_true, y_pred=y_pred, squared=True)
31 rmse = mean_squared_error(y_true=y_true, y_pred=y_pred, squared=False)
32 acc = accuracy_score(y_true, y_pred)
33
34 # Imprimiendo los resultados
35 print(f"\nResultados para el año {año} - con {len(targets_rlg)} datos:")
36 print(f"MAE: {mae}")
37 print(f"MSE: {mse}")
38 print(f"RMSE: {rmse}")
39 print(f'Accuracy: {:.2f}%'.format(acc*100))

```

```

1 #Arreglo años
2 years = [2017, 2018, 2019, 2020]
3
4 #Bucle para ejecutar proceso para cada año
5 for year in years:
6     procesar_rlg(year)

```

Resultados para el año 2017 - con 46592 datos:

MAE: 0.10186298076923077
MSE: 0.10194883241758242
RMSE: 0.31929427244719316
Accuracy: 89.82%

Resultados para el año 2018 - con 48087 datos:

MAE: 0.08811113190675235
MSE: 0.08815272318921955
RMSE: 0.2969052427782634
Accuracy: 91.19%

Resultados para el año 2019 - con 48657 datos:

MAE: 0.04067246233840968
MSE: 0.041289023162134945
RMSE: 0.20319700579027966
Accuracy: 95.96%

Resultados para el año 2020 - con 45551 datos:

MAE: 0.22161972294790455
MSE: 0.22166362977761192
RMSE: 0.4708116712419223
Accuracy: 77.84%

```

1 def procesar_rlg_all():
2     # Remover Outliers
3     df1 = df[(df['ROE'] > -1) & (df['ROE'] < 1) & (df['ROA'] > -1) & (df['ROA'] < 1) & (df['ENDEUDAMIENTO DEL ACTIVO'] < 6) & (df['RENTABILIDAD NETA DE VENTAS'] > -50) &
4         (df['UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ' > -5) & (df['UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ' < 5) & (df['RENTABILIDAD FINANCIERA'] < 500)]
5     df1['ROA_DIS'] = pd.qcut(df1['ROA'], 3, labels=False)
6     # Input y Targets
7     inputs_rlg = df1[['RENTABILIDAD NETA DEL ACTIVO', 'UTILIDAD OPERACIONAL/TOTAL DE ACTIVOS ', 'RENTABILIDAD FINANCIERA', 'RENTABILIDAD NETA DE VENTAS']].values
8     targets_rlg = df1[['ROA_DIS']].values
9     # Escalando los datos
10    scaler = StandardScaler()
11    inputs = scaler.fit_transform(inputs_rlg)
12    # Transformando los datos a tensores
13    inputs_rlg = torch.from_numpy(inputs.astype(np.float32))
14    targets_rlg = torch.from_numpy(targets_rlg.astype(np.int64))
15    # Creando el conjunto de datos de test
16    dataset_test = TensorDataset(inputs_rlg, targets_rlg)
17    test_loader = DataLoader(dataset_test, batch_size=bs, shuffle=True)
18    # Evaluando el modelo
19    y_pred = []
20    y_true = []
21    model_rlg.train(False)
22    for inputs, targets in test_loader:
23        y_hat_test = model_rlg(inputs).data.numpy()
24        y_hat_class = np.argmax(y_hat_test, axis=1)
25        y_pred.extend(y_hat_class)
26        y_true.extend(targets.numpy())
27    # Calculando métricas
28    mae = mean_absolute_error(y_true=y_true, y_pred=y_pred)
29    mse = mean_squared_error(y_true=y_true, y_pred=y_pred, squared=True)
30    rmse = mean_squared_error(y_true=y_true, y_pred=y_pred, squared=False)
31    acc = accuracy_score(y_true, y_pred)
32    cm = confusion_matrix(y_true, y_pred)
33
34
35    # Imprimiendo los resultados
36    print(f"\nResultados para el año - con {len(targets_rlg)} datos:")
37    print(f"MAE: {mae}")
38    print(f"MSE: {mse}")
39    print(f"RMSE: {rmse}")

```

```
40 print('Accuracy: {:.2f}%'.format(acc*100))
41 print(f"Confusion Matrix: ")
42 disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=['ROA Bueno', 'ROA Medio', 'ROA Malo'])
43 disp.plot()
44 plt.show()
```

```
1 procesar_rlg_all()
```

Resultados para el año - con 188887 datos:


MAE: 0.0027953220708677676

MSE: 0.0028059104120452968

RMSE: 0.05297084492478194

Accuracy: 99.72%

Confusion Matrix:



[Productos de pago de Colab](#) - [Cancelar contratos](#)

